

Defensible Space

Detección automática de incumplimiento del protocolo municipal de prevención de incendios de interfase urbano-forestal en Villa La Angostura

Trabajo Práctico Final · Visión por Computadora III · MIA FIUBA

Octubre 2026 · M. Belén Cattaneo

Resumen. Se compara empíricamente la familia Vision Transformer (Mask2Former con backbones Swin-T y Swin-S) contra la familia CNN (YOLOv8-seg en tamaños nano y large) sobre segmentación por instancias de imágenes aéreas de dron de Villa La Angostura. El estudio es un *ablation* factorial sobre cuatro ejes: arquitectura, capacidad, dataset y evaluador, con un *ground truth* oracular de 50 imágenes etiquetado con criterios documentados como referente más limpio. El campeón de mAP es Mask2Former + Swin-T entrenado con 927 imágenes mixtas, con 0,643 mAP@0,5 sobre oracular. A parámetros equiparables (47 M vs 46 M) la ViT supera a YOLOv8l-seg por 11,1 puntos. El *pipeline* de producción va del tileado al mapa interactivo con alertas de incumplimiento del protocolo municipal de *defensible space*.

1. Objetivo del proyecto

1.1. Problema y aplicación

El trabajo aborda la detección automática de incumplimiento del protocolo municipal de *defensible space* en Villa La Angostura, Neuquén, mediante segmentación por instancias sobre imágenes aéreas de dron. El protocolo, publicado por la Dirección de Protección Civil para mitigar la propagación de incendios de interfase urbano-forestal, establece que ninguna vegetación debe encontrarse a menos de dos metros de una estructura habitacional. El *pipeline* produce, dada una ortofoto de dron, un mapa interactivo donde cada edificio aparece coloreado según su cumplimiento. El trabajo se enmarca en la convocatoria Open Call 2026 del *Humanitarian OpenStreetMap Team* (HOT).

1.2. Pregunta de investigación

¿El sesgo inductivo débil de los Vision Transformers constituye una desventaja significativa frente a un baseline CNN en datasets de dominio específico con pocas muestras, o el pre-entrenamiento masivo lo compensa?

Se aborda empíricamente comparando dos familias pre-entrenadas en COCO sobre el mismo dataset de dos clases (building y trees_and_bushes): YOLOv8-seg (CNN) y Mask2Former con backbone Swin (ViT). La comparación limpia requiere controlar cuatro variables: arquitectura, capacidad del modelo, dataset (volumen y ontología) y *ground truth* (GT) de evaluación. El estudio se armó como un diseño factorial que se describe en Sección 4.

2. Arquitectura general




Figura 1: Arquitectura del sistema. La ortofoto del dron se procesa en cinco etapas hasta producir un mapa interactivo con las alertas.

Descripción breve de cada componente del sistema de la Figura 1:

1. **Modelo de segmentación:** red neuronal entrenada para distinguir edificios y vegetación en imágenes aéreas. Es el único componente que requirió un desarrollo iterativo largo (ver Sección 4). El modelo final elegido se usa como caja negra desde el sistema de producción.
2. **Fragmentación:** la ortofoto completa (típicamente varios cientos de MB) se divide en imágenes más chicas con solapamiento controlado para que la detección pueda hacerse con una red de tamaño fijo sin perder los objetos que caen sobre los bordes.
3. **Detección:** por cada imagen chica, el modelo entrenado identifica los contornos de los edificios y de la vegetación. La salida es un conjunto de máscaras por clase para esa imagen.
4. **Cálculo de distancia:** sobre esas máscaras se calcula geométricamente la distancia mínima de cada edificio a la vegetación más cercana. Es el primer criterio de incumplimiento del protocolo de dos metros.
5. **Agregación geoespacial:** las alertas se consolidan en coordenadas geográficas reales, se deduplican edificios repetidos por el solapamiento entre imágenes y se refina la clasificación según el área total de vegetación dentro del *buffer* de dos metros de cada edificio (demota violaciones por árboles sueltos y promueve edificios con masa continua de vegetación cercana).
6. **Generación del mapa:** con las alertas georreferenciadas y el ortomosaico de fondo se construye un mapa web interactivo que la Dirección de Protección Civil puede abrir en el navegador para inspeccionar cada edificio y su estado de cumplimiento.

3. Implementación técnica

3.1. Captura de imágenes aéreas

Las imágenes se capturaron con un *DJI Mini 5 Pro* operado mediante el control remoto. La planificación de los vuelos se realizó con *Drone Tasking Manager*, una plataforma de HOT que divide un área de interés en tareas de vuelo acotadas, asigna cada tarea a un piloto, verifica la captura y gestiona el procesamiento posterior en *OpenDroneMap* (ODM) para generar el ortomosaico publicado en *OpenAerialMap* (OAM).

Se crearon dos proyectos cubriendo regímenes distintos del área de estudio:

- "Defensible Space: Correntoso/Arauco": baja densidad residencial sobre bosque cerrado.
- "Defensible Space: Lomas del Correntoso/Norte": interfaz urbano-forestal, residencial denso.




Figura 2: Proyecto "Defensible Space: Correntoso/Arauco" en Drone Tasking Manager. El área (1,179 km²) se dividió en 25 tareas de 300 m de lado.




Figura 3: Proyecto "Defensible Space: Lomas del Correntoso/Norte". El área (0,729 km²) se dividió en 12 tareas de 350 m con Terrain Following activo.

Los parámetros se eligieron para obtener resolución espacial suficiente para distinguir vegetación individual y bordes de edificaciones (*Ground Sampling Distance*, GSD, en torno a los 3-4 cm/px) manteniendo tiempos de vuelo razonables. Los *overlaps* del 75% en ambos ejes garantizan la cobertura necesaria para que ODM reconstruya el ortomosaico sin huecos.

Parámetro	Correntoso/Arauco	Lomas del Correntoso/Norte
Área total	1,179 km ²	0,729 km ²
Cantidad de tareas	25	12
Tamaño de tarea	300 m	350 m
Altitud de vuelo	118,8 m	100 m
GSD	4 cm/px	3,37 cm/px
Overlap frontal y lateral	75% y 75%	75% y 75%
Terrain Following	No	Sí

Tabla 1: Parámetros de vuelo por proyecto en Drone Tasking Manager.

3.2. Dataset y splits

El dataset se construyó a partir de la ortofoto (imagen aérea georreferenciada con corrección geométrica para escala uniforme) de cada tarea individual, no del mosaico global del proyecto, para evitar propagar errores de alineación entre tareas vecinas. En Correntoso/Arauco, que tiene

la topografía más irregular, *Terrain Following* estuvo desactivado, lo que puede introducir cambios locales de escala en zonas de altitud variable. A partir de esa experiencia, en Lomas del Correntoso/Norte se activó el parámetro para mitigar esa deformación.

El etiquetado se realizó en **Roboflow** con *Smart Polygon* (**SAM** asistido). El proyecto inicial fue etiquetado íntegramente por la autora y el dataset expandido se produjo con el aporte del equipo Lawal.

Dataset	Train	Val	Test	Anotaciones	Labelers
86 autora	50	18	18	1.236	autora
927 mix	641	147	139	10.362	autora + equipo Lawal
486 autora	332	77	77	4.116	autora
<i>held-out team</i>	-	-	441	6.246	equipo Lawal
oracular	-	-	50	1.270	autora, criterios documentados

Tabla 2: Datasets usados en los experimentos y su composición en los splits de training, validación y test.

El *held-out team* se construye con las 441 imágenes etiquetadas exclusivamente por el equipo Lawal, extraídas de los tres *splits* del 927 mix. Es verdadero *held-out* para los *runs* entrenados sobre "solo autora" (86 autora y 486 autora), que nunca vieron esas imágenes. Para los *runs* entrenados sobre 927 mix (que ya incluye las 441 del equipo), el *held-out team* mide ajuste al estilo del equipo más que generalización pura, y por eso se complementa con el oracular. El dataset oracular se construye re-etiquetando 50 imágenes del *held-out team* por la autora con criterios documentados por escrito. El oracular es independiente de los tres *splits* de entrenamiento (ningún modelo vio esas re-etiquetas) y además unifica la ontología de etiquetado, por lo que es el referente limpio para comparar *runs* entrenados sobre datasets distintos.

3.3. Modelos comparados

Se compararon dos familias pre-entrenadas en COCO, cada una en al menos dos tamaños para habilitar comparaciones a parámetros equiparables.

Familia CNN

YOLOv8-seg (Ultralytics). Arquitectura *one-stage anchor-free* con *backbone* **CSPDarknet**, *neck* **PANet** y cabezal que combina coeficientes de máscara con un banco de prototipos compartidos (estilo **YOACT**). Variantes evaluadas: **YOLOv8n-seg** (nano, 3,3 M, 1024×1024) y **YOLOv8l-seg** (large, 46 M, 1024×1024 sobre 86 imágenes y 640×640 sobre 927 por memoria).

Familia ViT

Mask2Former con *backbone* **Swin**. Arquitectura *encoder-decoder* con atención enmascarada: Swin tokeniza en parches y aplica autoatención local en ventanas desplazadas con jerarquía multi-escala, un *pixel decoder* refina los mapas y un *transformer decoder* con 100 *queries* aprendidas resuelve la segmentación con asignación bipartita óptima estilo **DETR**. Variantes:

`Swin-T` (47 M) y `Swin-S` (69 M). Ambas entrenadas a 384×384 por memoria del dispositivo (Apple M4 MPS, 24 GB). Swin-B y Swin-L no entraron en memoria.

3.4. Stack técnico

Dominio	Herramienta	Rol
<i>Deep learning</i>	<code>PyTorch</code> 2.14	Framework base, backend MPS
Modelo CNN	<code>Ultralytics YOLOv8</code>	YOLOv8n-seg y YOLOv8l-seg con API de <i>training</i>
Modelo ViT	<code>HuggingFace Transformers</code>	Mask2Former + Swin-T y Swin-S pre-entrenados
<i>Augmentation</i>	<code>Albumentations</code>	Transformaciones imagen y máscara consistentes
Etiquetado	<code>Roboflow</code>	<i>Smart Polygon</i> asistido por SAM, dataset management
Captura y planificación	Drone Tasking Manager, OpenDroneMap, OpenAerialMap	Flujo abierto de vuelo, ortofoto y publicación
Geoespacial	<code>rasterio</code> , <code>shapely</code>	<i>Geotransforms</i> , operaciones poligonales
Visualización	<code>Folium</code> (<code>Leaflet.js</code>)	Mapa interactivo HTML
Evaluación	<code>pycocotools</code>	mAP estándar COCO
Imagen	<code>Pillow</code> , <code>OpenCV</code> , <code>scipy.ndimage</code>	Máscaras, contornos, EDT

Tabla 3: Stack técnico utilizado en el proyecto por dominio funcional.

3.5. Módulos clave

Etapa	Módulos (<code>src/</code>)	Rol
Preparación	<code>tile</code> , <code>coco_to_yolo</code> , <code>build_dataset</code> , <code>build_oracular_sample</code> , <code>merge_oracular_splits</code>	Tileado 1024×1024, conversión COCO a YOLO, construcción de <i>test sets</i> cruzado y oracular
Training	<code>train_yolo_seg</code> , <code>train_mask2former</code>	<i>Fine-tuning</i> de ambas familias con parámetros vía variables de entorno
Evaluación	<code>evaluate_m2f</code> , <code>evaluate_yolo</code> , <code>compare_models</code>	mAP con <code>pycocotools</code> (mismo pipeline para ambos modelos) y grillas visuales GT contra predicciones
Alertas	<code>compute_alerts</code> , <code>aggregate_alerts</code>	<i>Distance transform</i> y clasificación por regla de 2 m, deduplicación entre <i>tiles</i> y georreferenciación a <i>World Geodetic System 1984</i> (WGS84)
Mapa	<code>build_mosaic</code> , <code>generate_map</code>	Mosaico reproyectado a Web Mercator y mapa HTML interactivo con <code>Folium</code>

4. Evaluación

4.1. Protocolo de evaluación

Las métricas se calculan con la librería `pycocotools` usando intersección sobre unión (*Intersection over Union*, IoU) de segmentación. Se reportan mAP@0.5 y mAP@0.5:0.95, promediados entre clases y evaluados por clase individualmente. Se evalúan tres regímenes de *ground truth*:

1. *Test* propio de cada *run*: el *split* de test del dataset con el que entrenó.
2. Evaluación cruzada sobre *held-out* team: 441 imágenes etiquetadas por el equipo Lawal. Verdadero *held-out* para los *runs* entrenados sobre "solo autora" (86 autora, 486 autora). Para los *runs* entrenados sobre 927 mix esas imágenes son parte del conjunto de *training*, por lo que la métrica mide ajuste al estilo del equipo, no generalización.
3. Evaluación sobre *ground truth* oracular: 50 imágenes del *held-out* team re-etiquetadas por una sola persona (autora) con criterios documentados por escrito. Es el referente más limpio porque la ontología de etiquetado es uniforme para toda la tabla.

Nota técnica sobre la extracción de instancias de Mask2Former: la red predice 100 *queries* fijas por imagen y cada una es una propuesta de instancia (máscara + score + clase). Para calcular mAP de segmentación de instancias con `pycocotools` hay que recibirlas como máscaras binarias *independientes*, porque dos instancias pueden solaparse píxel a píxel. El *wrapper* `post_process_instance_segmentation` de HuggingFace devuelve ese formato cuando se pasa la opción `return_binary_maps=True`. Sin la *flag*, el *wrapper* construye un mapa panóptico `int32` donde cada píxel se asigna a una sola instancia por `argmax(mask_probs * scores)`, formato no apropiado para mAP de instancias porque fuerza píxeles únicos y subestima la métrica. El propio *docstring* de `transformers` (`image_processing_mask2former.py:639`) lo advierte: "If instances could overlap, set either `return_coco_annotation` or `return_binary_maps` to `True` to get the correct segmentation result." El pipeline de evaluación (`src/models_io.py:m2f_instance_masks`) usa la *flag* correcta.

4.2. Diseño experimental

El estudio se organiza como un *ablation* factorial sobre cuatro ejes. No todas las combinaciones se evalúan pero las elegidas permiten aislar el efecto de cada eje por separado:

Eje	Niveles	Propósito
Arquitectura	CNN (YOLOv8), ViT (Mask2Former + Swin)	Sesgo inductivo fuerte vs débil
Capacidad	Chico (3,3 M), medio (46-47 M), grande (69 M)	Efecto del escalado de parámetros
Dataset	86 autora, 486 autora, 927 mix	Efecto del volumen y de la ontología de etiquetado
Evaluador	Test propio, <i>held-out</i> team, oracular	Efecto del <i>ground truth</i> sobre el <i>ranking</i>

Tabla 4: Ejes del diseño experimental con los niveles explorados.

4.3. Recorrido experimental

El objetivo original era comparar YOLOv8n (3,3 M) contra Mask2Former + Swin-T (47 M) sobre un único dataset chico. La numeración vN de los *runs* es incremental sobre todo el proceso de experimentación. Los *runs* v1 a v7 fueron iteraciones exploratorias previas al pulido metodológico (hiperparámetros definitivos, *early stop* desactivado, *augmentation* mínima) y no se incluyen en las tablas finales.

Paso	Run	mAP@0.5	Hipótesis probada	Veredicto
1	v9 YOLO v9 M2F	0.221 0.532	Baseline sobre 86 imágenes de una sola anotadora.	baseline
2.1	v8 YOLO v8 M2F	0.516 0.643	Al escalar a 927 imágenes mixtas, mejoran las métricas respecto al baseline.	confirmada
2.2	v10 YOLO v10 M2F	0.335 0.599	Al filtrar labels del equipo Lawal, las métricas recuperan hacia los baselines.	parcial
3.1	v11 YOLO (YOLOv8l, 86)	0.405	Escalar params de YOLO (46 M) a parámetros comparables con M2F mejora sobre dataset chico.	parcial
3.2	v12 YOLO (YOLOv8l, 927)	0.532	Escalar params y data juntos maximiza capacidad en YOLO.	confirmada
3.3	v14 YOLO (YOLOv8l, 486)	0.378	La CNN escala también en el régimen intermedio de datos, respetando el patrón params+data.	descartada
4	Cruzada held-out	v9 YOLO: 0.135 v9 M2F: 0.326	El ranking entre runs depende del evaluador, no solo de la capacidad del modelo.	confirmada
5.1	Oracular	ver Tabla 7	Un ground truth con ontología consistente establece el ranking real de capacidad.	confirmada
5.2	v13 M2F (Swin-S, 927)	0.634	Escalar params de M2F (69 M) sobre 927 mix mejora respecto a Swin-T.	descartada
5.3	v14, v15 M2F (Swin-S, 86 y 486)	0.574 y 0.590	La escalada del ViT a Swin-S también mejora en regímenes de datos menores.	parcial, Swin-S y Swin-T quedan muy cerca en todos los regímenes

Tabla 5: Resumen de los experimentos agrupados por los cinco pasos de la narrativa, que luego se desarrolla paso por paso. Cada fila indica la hipótesis probada, su resultado y el veredicto final (**confirmado** , **descartado** , **parcial** , **abierto**).

El baseline sobre 86 imágenes de una única anotadora dio **Mask2Former + Swin-T** 0.483 mAP@0.5 sobre test propio y **YOLOv8n** 0.180. La brecha a favor del ViT ya se ve en el baseline chico.

Al escalar los datos el comportamiento sobre test propio se vuelve contradictorio entre arquitecturas: **Mask2Former + Swin-T** baja al cambiar de dataset, de 0.483 sobre 86 autora a 0.352 sobre 486 autora y a 0.372 sobre 927 mix, mientras **YOLOv8n** sube predeciblemente de 0.180 a 0.208 y a 0.312. Si el test propio fuera informativo, ambos modelos deberían haber escalado monótonicamente con más datos. Filtrar el dataset a solo etiquetas de la autora (486 autora, runs v10) tampoco uniformó la tendencia. El patrón divergente puso bajo sospecha al evaluador antes que al modelo.

Para romper la ambigüedad se construyeron dos referentes externos. Primero un *held-out* team de 441 imágenes etiquetadas solo por el equipo Lawal, que sirve como verdadero *held-out* para los *runs* entrenados en "solo autora" (86 y 486) pero no para los entrenados en 927 mix. Sobre el *held-out*, los *runs* 86 autora bajan fuertemente respecto a su test propio porque la ontología del evaluador es distinta: v9 Swin-T baja de 0.483 a 0.326 y v9 YOLOv8n baja de 0.180 a 0.135. Después un *ground truth* oracular de 50 imágenes del *held-out* team re-etiquetadas por la autora con criterios documentados (ver `data/oracular_relabel/README.md`), independiente de ambas particiones de entrenamiento. Sobre oracular el *ranking* final fue v8 Mask2Former + Swin-T 47 M 0.643, v13 Mask2Former + Swin-S 69 M 0.634, v10 Mask2Former + Swin-T 486 autora 0.599, v15 Mask2Former + Swin-S 486 autora 0.590, v14 Mask2Former + Swin-S 86 autora 0.574, v9 Mask2Former + Swin-T 86 autora 0.532 (empatado con v12 YOLOv8l 927 mix) y después toda la familia YOLO. Los seis *runs* M2F lideran los seis primeros puestos.




Figura 4: Curvas de entrenamiento de Mask2Former (train y val loss) para los runs relevantes del recorrido experimental.




Figura 5: Curvas de entrenamiento de YOLO (seg_loss y mAP@0.5 sobre validación) para los runs relevantes.

El recorrido descartó la explicación intuitiva del *label noise* inter-anotadoras como factor único y confirmó una: la métrica sobre test propio no refleja capacidad pura del modelo, sino coincidencia con la ontología del evaluador. Iteraciones exploratorias adicionales se omiten de las tablas por legibilidad: la *augmentation* extra con `flipud`, `degrees` y `copy_paste` no mejoró la métrica respecto a los defaults de Ultralytics y se descartó, el *early stop* por `val_loss` con `patience=5` corta antes del óptimo en *splits* chicos porque la señal de validación es muy ruidosa a este régimen y la caída de mAP al cortar temprano es grande, por lo que se desactivó para los *runs* reportados.

4.4. Resultados de evaluación

Cada *run* se evalúa bajo los tres regímenes de evaluación descritos en 3.2 (test propio, *held-out* team y oracular). La Tabla 6 reúne las tres métricas en una matriz arquitectura por dataset con *heatmap*: cada celda muestra los tres valores en orden *test*, *held-out*, oracular, y la intensidad del verde escala con la métrica en los *bins* 0,30, 0,40, 0,50, 0,60. Las celdas *held-out* para los *runs* entrenados sobre 927 mix se omiten porque esas 441 imágenes del equipo son parte del *training* del dataset y la métrica no sería un verdadero *held-out*. Permite leer el efecto de los datos por fila, el efecto de la capacidad por columna y el efecto del evaluador por línea dentro de cada celda.

Arquitectura	86 autora	486 autora	927 mix
YOLOv8n (3,3 M)	test 0.180	test 0.208	test 0.312
	held-out 0.135	held-out 0.222	held-out —
	oracular 0.221	oracular 0.335	oracular 0.516
	v9	v10	v8
YOLOv8l (46 M)	test 0.371	test 0.233	test 0.312
	held-out 0.249	held-out 0.244	held-out —
	oracular 0.405	oracular 0.378	oracular 0.532
	v11	v14	v12
Mask2Former + Swin-T (47 M)	test 0.483	test 0.352	test 0.372
	held-out 0.326	held-out 0.369	held-out —
	oracular 0.532	oracular 0.599	oracular 0.643
	v9	v10	v8
Mask2Former + Swin-S (69 M)	test 0.521	test 0.370	test 0.384
	held-out 0.345	held-out 0.370	held-out —
	oracular 0.574	oracular 0.590	oracular 0.634
	v14	v15	v13

Tabla 6: Matriz arquitectura por dataset con $mAP@0.5$ bajo los tres regímenes de evaluación como *heatmap*.

Patrones visibles. Dentro de cada celda, oracular está por encima del test propio en todas las celdas. La diferencia entre regímenes crece con el tamaño del dataset de *training*, lo que refleja que el ruido inter-anotadoras se expresa más cuando hay más labels en juego. Fila por fila, más datos ayudan monótonicamente a tres de las cuatro arquitecturas sobre oracular (YOLOv8n, Swin-T y Swin-S). YOLOv8l rompe el patrón con 486 autora (0.378, por debajo del 0.405 que da sobre 86 autora) y recupera sobre 927 mix. A parámetros equiparables (47 M vs 46 M), la ViT supera a la CNN en los tres regímenes de datos: por 12,7 puntos sobre 86 autora (Swin-T 0.532 vs YOLOv8l 0.405), 22,1 sobre 486 autora (0.599 vs 0.378) y 11,1 sobre 927 mix (0.643 vs 0.532). Escalar la ViT de Swin-T a Swin-S es prácticamente neutro (Swin-S aporta 4,2 puntos

sobre 86 autora pero resta 0,9 sobre 486 autora y 0,9 sobre 927 mix), lo que sugiere que la capacidad del ViT ya satura en el régimen explorado.

La Tabla 7 muestra el desglose por clase sobre oracular (50 imágenes, 1.270 anotaciones) para analizar el comportamiento diferencial en una clase geoméricamente bien definida (`building`) y una ontológicamente ambigua (`trees_and_bushes`). Ordenada por mAP@0.5 descendente.

Run	Arquitectura	Params	Dataset	mAP@0.5	<code>building</code>	<code>trees_and_bushes</code>
v8 M2F	Swin-T	47 M	927 mix	0.643	0.753	0.532
v13 M2F	Swin-S	69 M	927 mix	0.634	0.752	0.516
v10 M2F	Swin-T	47 M	486 autora	0.599	0.698	0.499
v15 M2F	Swin-S	69 M	486 autora	0.590	0.699	0.482
v14 M2F	Swin-S	69 M	86 autora	0.574	0.666	0.482
v9 M2F	Swin-T	47 M	86 autora	0.532	0.631	0.433
v12 YOLO	YOLOv8l	46 M	927 mix	0.532	0.593	0.470
v8 YOLO	YOLOv8n	3,3 M	927 mix	0.516	0.598	0.434
v11 YOLO	YOLOv8l	46 M	86 autora	0.405	0.440	0.369
v14 YOLO	YOLOv8l	46 M	486 autora	0.378	0.325	0.431
v10 YOLO	YOLOv8n	3,3 M	486 autora	0.335	0.303	0.368
v9 YOLO	YOLOv8n	3,3 M	86 autora	0.221	0.116	0.327

Tabla 7: Desglose de mAP@0.5 por clase sobre ground truth oracular.

4.5. Análisis

El evaluador modula el *ranking*

Las métricas sobre test propio no comparan solamente capacidades del modelo, también miden la coincidencia entre la ontología de etiquetado con la que el modelo entrenó y la del evaluador. En

el *held-out* team, los *runs* "solo autora" bajan fuertemente respecto a su test propio porque la ontología del equipo es distinta: Swin-T v9 86 autora baja de 0.483 a 0.326 y YOLO v9 86 autora baja de 0.180 a 0.135. Sobre oracular, con ontología uniforme para toda la tabla, Swin-T v8 queda primero con 0.643 y el ranking se estabiliza. El sesgo inductivo modula la amplitud del efecto: al cambiar del test propio al *held-out* team, el delta de Swin-T v9 86 autora es 0.157 contra 0.045 para YOLO v9 86 autora. El ViT con *queries* arranca de un nivel más alto y conserva más margen, mientras la CNN con *grid* denso se ajusta más al estilo específico de su train y pierde menos en términos absolutos.

Capacidad, datos y clase ambigua

Sobre oracular con 927 imágenes, M2F supera a YOLO a parámetros comparables (v8 Swin-T 47 M 0.643 vs v12 YOLOv8l 46 M 0.532) y escalar M2F a Swin-S 69 M no agrega ganancia marginal (0.634). Dentro de YOLO, agregar parámetros sin más datos mejora poco (v11 YOLOv8l 86 autora 0.405, v9 YOLOv8n 86 autora 0.221, +18 puntos). Combinar params más datos escala predeciblemente (v12 suma 1,6 puntos sobre v8 nano a 927 mix). La ventaja de M2F sobre YOLO se concentra en la clase `building`: v8 Swin-T 0.753 vs v12 YOLOv8l 0.593, +16 puntos. En `trees_and_bushes` M2F también gana pero por menos: 0.532 vs 0.470, +6,2 puntos. Los edificios tienen geometría consistente entre anotadoras y el *pre-training* en COCO del ViT aprende a definirlos con bordes precisos. Las copas de árbol son ontológicamente ambiguas y acortan la ventaja.

5. Resultados y ejemplos

5.1. Comparación visual de inferencias




Figura 6: Comparación sobre tile de barrio residencial. GT (izquierda), `YOLOv8l v12` (centro), `Mask2Former + Swin-T v8` (derecha). `building` en rojo, `trees_and_bushes` en verde. Los dos modelos a parámetros equiparables (46 M vs 47 M) con el mismo threshold de confianza 0,5.




Figura 7: Comparación sobre tile forestal cerrado con misma convención de colores que la Figura 6.

5.2. Pipeline del producto mínimo viable (MVP) de alertas

El *pipeline* toma la ortofoto de un sector y devuelve un mapa interactivo donde cada edificio aparece pintado según cumpla o no la regla de los dos metros. El sector se parte en imágenes chicas para que el modelo pueda procesarlas, se detectan las construcciones y la vegetación en cada una, y se mide cuán cerca pasa la vegetación de cada construcción. Si está a menos de dos metros, el edificio se marca como violación.

El paso siguiente une todo lo detectado en una vista única del sector completo. Los recortes vecinos se superponen a propósito, así que cada edificio puede aparecer repetido en varias piezas; esas apariciones se agrupan comparando cuánto se solapan geográficamente, de modo que dos recortes del mismo edificio queden como uno solo pero sin fusionar construcciones distintas que estén pegadas. Como criterio de refinamiento final, se mira cuánta vegetación hay alrededor de

cada edificio para evitar falsas alertas por un arbusto aislado y, al revés, para marcar como riesgo real a los edificios rodeados por una masa continua de vegetación aunque el modelo no la haya visto completa en una sola imagen.

Durante el desarrollo iterativo del *pipeline* se usó `YOLOv8l` como detector rápido para poder correr sectores completos en minutos sobre una laptop sin GPU, pero los mapas finales incluidos en el repo son con el campeón de mAP (`Mask2Former + Swin-T`). El resultado es un mapa web con el ortomosaico del dron de fondo, los edificios coloreados por estado y la vegetación cercana marcada sobre cada violación.

5.3. Resultados

Las Figuras 8 y 9 muestran capturas del mapa interactivo generado para cada sector con `Mask2Former + Swin-T`. El ortomosaico del dron aparece como fondo y las detecciones en *overlay*: azul para edificios que cumplen la regla de 2 m, rojo para los que la violan y amarillo para la vegetación dentro del *buffer*. El panel abajo a la derecha permite filtrar edificios y vegetación por confianza en vivo.



Figura 8: Mapa interactivo de Barrio Norte.



Figura 9: Mapa interactivo de Correntoso/Arauco.

El *pipeline* se corrió sobre los dos sectores anotados (Barrio Norte y Correntoso/Arauco) y se publicaron sus mapas en el repo. La tasa de incumplimiento no se reporta como número único porque depende del umbral de confianza que el usuario elige en el mapa interactivo. Dos cautelas de diseño conviene mencionar: el modelo tiende a sobre-detectar estructuras (incluye cobertizos, galpones y techados menores que no son habitacionales y fragmenta un mismo edificio en varias detecciones) y no distingue el tipo de vegetación próxima, lo que es importante porque un pastizal cerca de una casa no se propaga igual que un pino. En términos de orden entre sectores, ambos están en interfaz urbano-forestal y en Villa La Angostura es raro encontrar una vivienda sin vegetación arbórea en los dos metros alrededor.

6. Conclusiones y mejoras futuras

6.1. Respuesta a la pregunta de investigación

Sobre el referente oracular (Tabla 7), la comparación central del estudio se hace a parámetros equiparables: Mask2Former + Swin-T v8 (47 M, 927 mix) con 0.643 mAP@0.5 contra YOLOv8l v12 (46 M, 927 mix) con 0.532, una diferencia de 11,1 puntos a favor del ViT. Esta es la comparación menos ambigua porque la capacidad es prácticamente idéntica y los dos modelos se evaluaron con el mismo pipeline (pycocotools), mismo GT sanitizado, mismo *threshold* de confianza 0,001). Como control adicional se entrenó Mask2Former + Swin-S v13 (69 M, 927 mix) que dio 0.634 (*last*), apenas por debajo de Swin-T: escalar el ViT dentro de este régimen no agrega ganancia marginal. En el escalado inverso, dentro de YOLO, pasar de nano a large sobre 927 mix mejora solo 1,6 puntos (v8 YOLOv8n 3,3 M = 0.516 vs v12 YOLOv8l 46 M = 0.532).

En el régimen explorado el *pre-training* masivo del ViT compensa su sesgo inductivo débil frente a una CNN moderna y en los dos regímenes de datos de los que ya hay medición completa (ver Tabla 6) la ventaja del ViT sobre la CNN se mantiene. El resultado es consistente con los *benchmarks* de referencia (Mask2Former paper, COCO *instance seg*) donde los ViT pre-entrenados lideran la tarea a parámetros equiparables. La ventaja se concentra en la clase geométricamente bien definida *building*, donde las *queries* esparsas aprenden representaciones más precisas que los *feature maps* densos de la CNN cuando el *fine-tuning* parte de pesos pre-entrenados en millones de imágenes.

6.2. Limitaciones

- Dataset de 927 imágenes es chico para la tarea (los *benchmarks* de referencia usan 5.000+ anotaciones), lo que deja varianza entre *runs* considerable.
- El *ground truth* oracular es *single-rater*, no multi-rater con consenso. El estándar académico más riguroso requeriría 2-3 anotadoras más y mediador.
- Los *splits* train/val/test del 927 mix son por imagen tras el tileado con 20% de solapamiento, no por ortofoto fuente. Dos *tiles* solapados de la misma ortofoto pueden caer en *splits* distintos y producir *leakage* parcial en el test propio. El oracular, construido desde el *held-out* team con imágenes que ningún modelo vio en *training*, es inmune a este efecto, lo que refuerza la decisión de usarlo como referente principal.
- Las *labels* del equipo Lawal entraron al 927 mix sin un QA ciego formal entre anotadoras. El impacto se mitiga reportando por evaluador en Tabla 6 y usando oracular como juez final, pero el QA formal queda listado en 6.3 como primer trabajo futuro.
- El dispositivo (24 GB M4 MPS) obliga a *cap* de 384×384 en M2F y de 640×640 para YOLOv8l sobre 927 imágenes. Swin-B (107 M) y Swin-L (217 M) no entraron en memoria.

6.3. Trabajo futuro

1. QA del *labeling* del equipo con revisión *peer* en `Roboflow`, para incorporar las 441 adicionales sin degradar la ontología. Y *ground truth* oracular por consenso entre anotadoras para responder la pregunta de forma rigurosa.
2. Pre-etiquetado asistido con *human-in-the-loop* usando `SAM 2` para acelerar el trabajo manual sobre nuevas tandas de *tiles*, siempre con revisión final por anotadora.
3. Expansión a Zonas 2 y 3 del protocolo (el módulo de distancia ya acepta `threshold-m`) y clase adicional para pastizales o vegetación de bajo porte.
4. Evaluar M2F con Swin-B y Swin-L sobre hardware con más memoria para probar si los *backbones* grandes cierran la brecha.

7. Planificación del equipo

Trabajo Práctico Final en modalidad individual (M. Belén Cattaneo). Durante la fase de etiquetado se contó con el aporte del equipo de la cooperativa Lawal (Florencia Otárola, Martín Silva, Joaquín Mansilla), que colaboraron con 441 imágenes etiquetadas del dataset expandido.

Fase	Tareas incluidas	Responsable	Rango
Setup y captura	Repo, ambiente, vuelos con DJI Mini 5 Pro, procesamiento en ODM, publicación en OAM	autora	sep 2026
Datos y baseline	Tileado y etiquetado del dataset 86 autora, primeros <i>runs</i> de YOLOv8n y Mask2Former Swin-T	autora	22-23 sep
MVP de alertas	<code>compute_alerts</code> , <code>aggregate_alerts</code> , <code>build_mosaic</code> , <code>generate_map</code> , <i>deploy</i> sobre Barrio Norte y Correntoso/Arauco	autora	29 sep
Etiquetado expandido	841 <i>tiles</i> etiquetadas, armado del dataset 927 mix	equipo Lawal	sep-oct
<i>Training</i> escalado y ablation	<i>Runs</i> YOLO y M2F sobre 927 mix y luego sobre 486 autora filtrado	autora	3 oct
<i>Scaling</i> de parámetros	YOLOv8l v11 y v12, Mask2Former Swin-S v13	autora	4 oct
Oracular y evaluación cruzada	Selección y re-etiquetado de 50 <i>tiles</i> , evaluación de todos los <i>runs</i> sobre <i>held-out</i> team y oracular	autora	4 oct
Informe y entrega	Redacción del informe, <i>submission</i> , presentación en Clase 8	autora	4-12 oct

Tabla 8: Cronograma por fase, responsable y rango de fechas.

Referencias

- Vaswani, A. et al. (2017). *Attention Is All You Need*. NeurIPS.
- Dosovitskiy, A. et al. (2020). *An Image is Worth 16×16 Words*. ICLR.
- Liu, Z. et al. (2021). *Swin Transformer*. ICCV.
- Cheng, B. et al. (2022). *Masked-attention Mask Transformer for Universal Image Segmentation*. CVPR.
- Bolya, D. et al. (2019). *YOLOACT: Real-time Instance Segmentation*. ICCV.
- Redmon, J. et al. (2016). *You Only Look Once*. CVPR.
- Zhang, H. et al. (2023). *Understanding Why ViT Trains Badly on Small Datasets*. arXiv.
- Kirillov, A. et al. (2023). *Segment Anything*. ICCV.